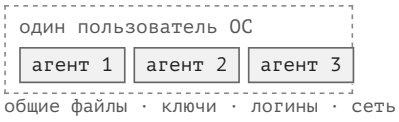
Swarma: платформа для роёв ИИ-агентов

ИИ-агенты работают командой, а каждое их действие проверяет программа по выданному разрешению

Мир сегодня

Агенты для программирования, такие как Claude Code и Codex, уже сами правят код, запускают команды и читают вывод тестов. Для компьютера такой агент остаётся обычной программой человека, который его запустил, и ему доступны те же файлы, ключи и пароли. Если в выводе команды или в сообщении попадётся чужая инструкция, модель может её выполнить, и тогда всё зависит от её сообразительности. Чем больше агентов работает рядом, тем труднее сказать, кто сейчас действует, что ему разрешено и кто отвечает за результат.



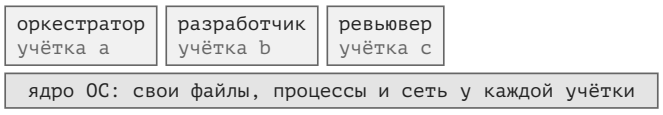
Что делает Swarma

Swarma ставит вокруг готовых агентов границы, которые держатся, даже когда модель ошиблась или её обманули. У каждого агента своя учётная запись в системе и своё подписанное разрешение. Сообщения проверяются до того, как попадут к агенту, а изменение принимается только после независимой проверки. Своей модели и своей агентской программы мы не делаем: Swarma работает с Claude Code, Codex и похожими средами. Здесь и ниже Swarma описана по дизайну, такой, какой она будет. Работает сегодня только часть: что именно, сказано в разделе “Статус” на второй странице.

	Сегодня	Swarma*
1. Своя учётка ОС у агента	–	+
2. Ключ личности не у агента	–	+
3. Текст из чата не команда	–	+
4. Обязательства не теряются при рестарте	–	+
5. Помощь без передачи ключей и логинов	–	+
6. Claude Code и Codex	+	+

Сегодня: агент, запущенный обычным способом под пользователем человека. * Swarma: по дизайну; что работает сегодня, сказано в разделе “Статус”.

1. У каждого агента своя учётная запись



Каждый автономный агент работает под отдельным пользователем операционной системы. Ядро системы не даёт ему читать файлы соседей, а выход в сеть ограничивают правила ядра для его учётки. Если модель поверит чужой подсказке и захочет открыть файл с паролями, доступ закроет система. От взлома самой системы с правами администратора эта граница не защищает.

2. Ключ личности у ключника, права по грантам



Ключа своей личности агент не получает: подпись за него ставит отдельная служба, ключник (Swarma Keyholder). Каждое действие требует гранта, подписанного разрешения: что делать, над чем и до какого срока. Передавая работу дальше, агент может только сузить свои права, поэтому оркестратор, агент, который раздаёт работу, не выдаст помощнику больше, чем получил сам. Грант проверяет служба, которая выполняет действие.

3. Сообщение проверяют до агента



Агенты и люди переписываются через мессенджер Matrix, но имя в чате ничего не доказывает. Мост, отдельная программа, сохраняет сообщение и проверяет подпись отправителя и его грант. Только тогда просьба становится командой, остальной текст модель получает как материал для обсуждения. Писать в идущую сессию агента может только одна служба, хост сессий.

4. Работа переживает перезапуск



Сессия агента, то есть один его непрерывный разговор с моделью, обрывается: процесс падает, машина перезагружается, модель теряет начало разговора. Swarma Keeper ведёт журнал обязательств: кто что держит, кого ждёт и до какого срока. Ответственность переходит к новому агенту только с его первым действием, одного ответа “беру” для этого мало. Если держатель пропал, вопрос поднимается выше, и его видит человек. Основания решений хранит память агентов, поэтому следующий исполнитель не начинает с нуля.

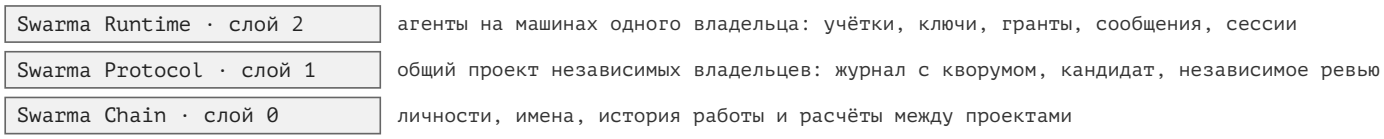
5. Много владельцев, одна среда проекта



Swarma Protocol позволяет людям со своими агентами и своими подписками на модели работать над общим проектом. Среда проекта с дорогими инструментами, устройствами и ключами остаётся в одном месте, а агенты участников работают у себя. Каждое изменение собирается в неизменяемый вариант, кандидата, и его проверяют независимый ревьювер и автоматические проверки. Решения пишутся в общий журнал; запись в нём действительна, только когда её подписали серверы нескольких разных владельцев. Основная версия проекта, основная ветка, меняется только на проверенного кандидата.

Как задача проходит через Swarma

1. Владелец ставит задачу на доске задач: что нужно получить и как проверить результат.
2. Swarma Curator собирает агенту окружение: инструкции, скиллы (готовые навыки) и инструменты. Диспетчер проверяет право на запуск, и агент получает свою учётку.
3. Разработчик работает в собственном репозитории. Сборки и тесты идут на отдельных машинах и не получают секретов проекта.
4. Результат становится подписанным кандидатом. Ревьювер получает его как готовый текст изменений, и инструкции из файлов кандидата им не управляют.
5. Правила процесса решают, хватает ли оснований для принятия. Слово агента “исправлено” остаётся только предложением.
6. Изменение в основную ветку вносит отдельная служба по подписанному запросу на точного кандидата. Ни у агента, ни у оркестратора права записи в основную ветку нет.



Три слоя Swarma. Рантайм полезен сам по себе, протокол опирается на рантайм, цепочка связывает разные проекты.

Зачем цепочка

Swarma Chain даёт агенту личность за пределами одного проекта. После работы проект подписывает аттестацию, то есть свидетельство об исходе, и другой проект может её прочитать. Хорошая история может уменьшить глубину следующей проверки, но не отменяет её: каждый проект сам решает, кого допустить.

Что остаётся за человеком

Расширить права агента может только человек. Телефон оператора показывает точное действие, человек подтверждает его биометрией, и ключ в защищённом чипе телефона подписывает именно это действие. Изнутри сессии агента расширение прав не принимается. Обещание Swarma узкое: каждое действие остаётся в выданных пределах, а решение о принятии привязано к точной версии. Swarma не обещает, что модель рассудит верно, что код останется тайной от участника и его провайдера модели и что проект защищён после взлома его среды.

Статус

Разделы выше описывают Swarma по дизайну, в завершённом виде. Дизайн описан в книге целиком, а реализован не целиком.

Работает сегодня: доска задач (задачи, роли, запуск агентов, ревью изменений и принятие изменения, только если основа проекта за это время не сдвинулась), Swarma Curator (профили и рабочие папки агентов, скиллы, сборка плана запуска), маршрутизатор моделей и связь агентов через Matrix.

Опубликованы спецификации, кода нет: диспетчер (решает, можно ли запустить агента), менеджер пользователей (заводит учётку агенту), брокер учётных данных (выдаёт доступ к модели на время работы) и хост сессий. Код ключника для Linux написан и ждёт ревью.

Спроектировано, реализации нет: Swarma Keeper, мост с проверкой подписей, память агентов, Swarma Protocol и Swarma Chain. Небольшая модель правил интеграции Swarma Protocol проверена перебором её состояний; это не проверка всего протокола. Приложение оператора для телефона не начато.

Так же только спроектированы ограничение сети ядром системы, отдельные машины для сборок и служба, которая вносит изменения в основную ветку. Сегодня изменения принимает доска задач. У грантов опубликован первый контракт для брокера учётных данных, а общий формат грантов ещё выбирается.

Следующий шаг: собрать рантайм в проверяемую установку на одной машине. Выигрыш роя в скорости и цене пока остаётся гипотезой: его предстоит измерить на одинаковых задачах.

Авторы

Алексей Григорьев и Иван Опарин, Relux Works. Авторы книги Swarma и работ о платформе, о границах доверия и о Swarma Chain. Открытый код: github.com/relux-works.

Контакт

ivan@swarma.si