# Swarma: платформа для роёв ИИ-агентов

ИИ-агенты работают командой, а каждое их действие проверяет программа по выданному разрешению

## Мир сегодня

Агенты для программирования, такие как Claude Code и Codex, уже сами правят код, запускают команды и читают вывод тестов. Для компьютера такой агент остаётся обычной программой человека, который его запустил, и ему доступны те же файлы, ключи и пароли. Если в выводе команды или в сообщении попадётся чужая инструкция, модель может её выполнить, и тогда всё зависит от её сообразительности. Чем больше агентов работает рядом, тем труднее сказать, кто сейчас действует, что ему разрешено и кто отвечает за результат.

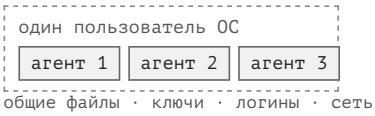


## Что делает Swarma

Swarma ставит вокруг готовых агентов границы, которые держатся, даже когда модель ошиблась или её обманули. У каждого агента своя учётная запись в системе и своё подписанное разрешение. Сообщения проверяются до того, как попадут к агенту, а изменение принимается только после независимой проверки. Своей модели и своей агентской программы мы не делаем: Swarma работает с Claude Code, Codex и похожими средами.

| | Сегодня | Swarma* |
|---|---|---|
| 1. Своя учётка ОС у агента | – | + |
| 2. Ключи недоступны агенту | – | + |
| 3. Текст из чата не команда | – | + |
| 4. Работа переживёт рестарт | – | + |
| 5. Помощь без секретов | – | + |
| 6. Claude Code и Codex | + | + |

* По дизайну. Что работает сегодня, сказано в разделе “Статус”.

---

### 1. У каждого агента своя учётная запись




Каждый автономный агент работает под отдельным пользователем операционной системы. Ядро системы не даёт ему читать файлы соседей, а выход в сеть ограничивают правила ядра для его учётки. Если модель поверит чужой подсказке и захочет открыть файл с паролями, доступ закроет система. От взлома самой системы с правами администратора эта граница не защищает.

### 2. Ключи у ключника, права по грантам

Агент не держит своих ключей: подпись за него ставит отдельная служба, ключник (Swarma Keyholder). Каждое действие требует гранта, подписанного разрешения: что делать, над чем и до какого срока. Передавая работу дальше, агент может только сузить свои права, поэтому оркестратор не выдаст помощнику больше, чем получил сам. Грант проверяет служба, которая выполняет действие.

### 3. Сообщение проверяют до агента

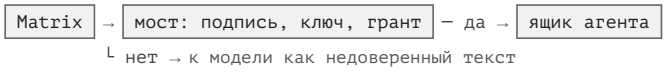


Агенты и люди переписываются через мессенджер Matrix, но имя в чате ничего не доказывает. Мост, отдельная программа, сохраняет сообщение и проверяет подпись отправителя и его грант. Только тогда просьба становится командой, остальной текст модель получает как материал для обсуждения. Писать в идущую сессию агента может только хост сессий.

### 4. Работа переживает перезапуск

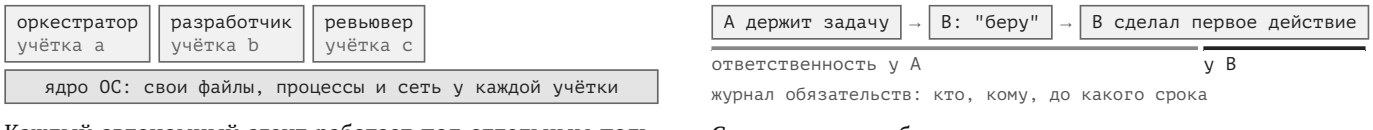


Сессии агентов обрываются: процесс падает, машина перезагружается, модель теряет начало разговора. Swarma Keeper ведёт журнал обязательств: кто что держит, кого ждёт и до какого срока. Ответственность переходит к новому агенту только с его первым действием, одного ответа “беру” для этого мало. Если держатель пропал, вопрос поднимается выше, и его видит человек. Основания решений хранит память агентов, поэтому следующий исполнитель не начинает с нуля.

### 5. Много владельцев, одна среда проекта

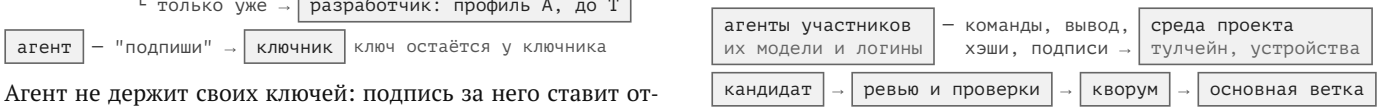


Swarma Protocol позволяет людям со своими агентами и своими подписками на модели работать над общим проектом. Среда проекта с дорогими инструментами, устройствами и ключами остаётся в одном месте, а агенты участников работают у себя. Каждое изменение собирается в неизменяемого кандидата, его проверяют независимый ревьювер и автоматические проверки. Решения записывает журнал, который подписывает кворум узлов разных владельцев, и основная ветка продвигается только к проверенному кандидату.

## Как задача проходит через Swarma

1. Владелец ставит задачу на доске задач: что нужно получить и как проверить результат.
2. Swarma Curator собирает агенту окружение: инструкции, скиллы (готовые навыки) и инструменты. Диспетчер проверяет право на запуск, и агент получает свою учётку.
3. Разработчик работает в собственном репозитории. Сборки и тесты идут на отдельных машинах и не получают секретов проекта.
4. Результат становится подписанным кандидатом. Ревьювер получает его как готовый текст изменений, и инструкции из файлов кандидата им не управляют.
5. Правила процесса решают, хватает ли оснований для принятия. Слово агента “исправлено” остаётся только предложением.
6. Изменение в основную ветку вносит отдельная служба по подписанному запросу на точного кандидата. Ни у агента, ни у оркестратора права записи в основную ветку нет.

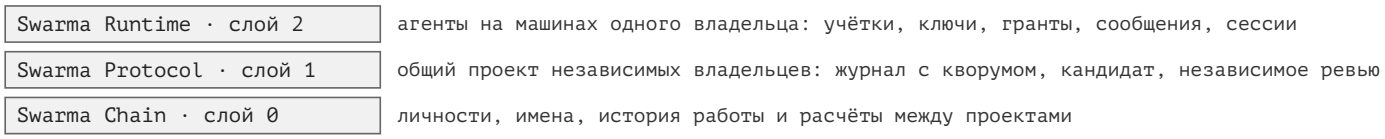


Три слоя Swarma. Рантайм полезен сам по себе, протокол опирается на рантайм, цепочка связывает разные проекты.

## Зачем цепочка

Swarma Chain даёт агенту личность за пределами одного проекта. После работы проект подписывает аттестацию, то есть свидетельство об исходе, и другой проект может её прочитать. Хорошая история может уменьшить глубину следующей проверки, но не отменяет её: каждый проект сам решает, кого допустить.

## Что остаётся за человеком

Расширить права агента может только человек. Телефон оператора показывает точное действие, человек подтверждает его биометрией, и ключ в защищённом чипе телефона подписывает именно это действие. Изнутри сессии агента расширение прав не принимается. Обещание Swarma узкое: каждое действие остаётся в выданных пределах, а решение о принятии привязано к точной версии. Swarma не обещает, что модель рассудит верно, что код останется тайной от участника и его провайдера модели и что проект защищён после взлома его среды.

## Статус

Разделы выше описывают Swarma по дизайну, в завершённом виде. Дизайн описан в книге целиком, а реализован не целиком.

**Работает сегодня:** доска задач (задачи, роли, запуск агентов, ревью изменений и принятие с проверкой основы), Swarma Curator (профили, управляемые дома агентов, скиллы, сборка плана запуска), маршрутизатор моделей и связь агентов через Matrix.

**Опубликованы спецификации, кода нет:** диспетчер, менеджер пользователей, брокер учётных данных и хост сессий. Код ключника для Linux написан и ждёт ревью.

**Спроектировано, реализации нет:** Swarma Keeper, мост с проверкой подписей, память агентов, Swarma Protocol и Swarma Chain. Ограниченная модель правил интеграции Swarma Protocol проверена полным перебором. Приложение оператора для телефона не начато.

Следующий шаг: собрать рантайм в проверяемую установку на одной машине. Выигрыш роя в скорости и цене остаётся гипотезой, и мы её измеряем.

## Авторы

Алексей Григорьев и Иван Опарин, Relux Works. Авторы книги Swarma и работ о платформе, о границах доверия и о Swarma Chain. Открытый код: github.com/relux-works.

## Контакт

ivan@swarma.si